

Санкт-Петербургский государственный университет

Математико-механический факультет

**Сложность выборки для ERM в
стохастических
седловых задачах**

Обобщение результатов Carmon, Livni, Yehudayoff (2023)
на выпукло-вогнутый случай

Курсовая работа

Выполнил: [Имя студента]

Научный руководитель: [ФИО]

Санкт-Петербург, 2025

Содержание

1	Введение	2
1.1	Контекст	2
1.2	Наш вклад	2
2	Исходная задача и результат Carmon–Livni–Yehudayoff	2
2.1	Постановка задачи минимизации	2
2.2	Главный результат	3
2.3	Ключевые идеи доказательства	3
3	Седловая задача: постановка и определения	3
3.1	Формальная постановка	3
4	Вспомогательные результаты	4
4.1	Субградиентное исчисление	4
4.2	Стохастическое условие первого порядка	5
4.3	Пара дивергенций Брегмана	5
4.4	Связь дивергенций с duality gap	6
4.5	Концентрационная лемма	6
5	Аналоги ключевых утверждений для седловой задачи	7
5.1	Контроль линейного члена	7
5.2	Утверждение о малости эмпирических дивергенций (аналог Claim 6)	7
5.3	Утверждение о связи gap с дивергенциями (аналог Claim 5)	8
6	Основная теорема	8
6.1	Формулировка	8
6.2	Доказательство	9
6.3	Обобщение на произвольные нормы	10
7	Нижняя граница и разделение с равномерной сходимостью	10
7.1	Нижняя граница	10
7.2	Разделение с равномерной сходимостью	11
8	Заключение	11

Аннотация

Статья Carmon, Livni, Yehudayoff (2023) решила открытую проблему Фельдмана: для стохастической выпуклой оптимизации (SCO) сложность выборки любого ERM равна $\tilde{O}(d/\varepsilon + 1/\varepsilon^2)$. В настоящей работе мы обобщаем этот результат на стохастические седловые задачи вида $\min_{x \in \mathcal{X}} \max_{y \in \mathcal{Y}} \mathbb{E}_z[f(x, y, z)]$, где f выпукла по x и вогнута по y . Мы показываем, что при $n \geq \tilde{O}((d_x + d_y)/\varepsilon + 1/\varepsilon^2)$ любой Saddle-ERM — алгоритм, возвращающий седловую точку эмпирического функционала, — достигает duality gap не более $O(\varepsilon)$ с высокой вероятностью. Доказательство следует методологии оригинальной статьи: стохастическое условие первого порядка, пара дивергенций Брегмана, концентрационные неравенства Бернштейна и аргумент ε -сети по совместному пространству $\mathcal{X} \times \mathcal{Y}$.

1 Введение

1.1 Контекст

Стохастическая выпуклая оптимизация (SCO) — стандартная модель для изучения статистических свойств алгоритмов обучения. В классической постановке задачи минимизации алгоритм ERM (Empirical Risk Minimizer) минимизирует эмпирический риск по выборке, и вопрос состоит в том, как много точек данных необходимо, чтобы любой ERM автоматически хорошо работал на истинном распределении.

Фельдман [2] показал, что для ERM в SCO необходимо $\Omega(d/\varepsilon + 1/\varepsilon^2)$ точек, и предложил как открытую проблему вопрос о достаточности этого количества. Carmon, Livni, Yehudayoff [1] закрыли этот вопрос, доказав, что $\tilde{O}(d/\varepsilon + 1/\varepsilon^2)$ точек *достаточно*. Это разделяет сложность ERM и равномерной сходимости (которая требует $\Theta(d/\varepsilon^2)$) и неожиданно объединяет два режима обучения в одной модели.

1.2 Наш вклад

Мы обобщаем результат [1] на задачу стохастической выпукло-вогнутой оптимизации:

$$\min_{x \in \mathcal{X}} \max_{y \in \mathcal{Y}} F(x, y), \quad F(x, y) = \mathbb{E}_{z \sim \mathcal{D}}[f(x, y, z)].$$

Алгоритм *Saddle-ERM* находит седловую точку эмпирического функционала $\hat{F}$, а качество решения измеряется через *duality gap*. Основной результат:

Основная теорема (неформально). Если $n \geq \tilde{O}((d_x + d_y)/\varepsilon + 1/\varepsilon^2)$, то с вероятностью не менее $3/4$ любой Saddle-ERM $(\hat{x}, \hat{y})$ удовлетворяет $\text{Gap}_F(\hat{x}, \hat{y}) \leq C\varepsilon$ для абсолютной константы C .

Доказательство состоит из семи шагов: (1) постановка задачи и определения, (2) стохастическое условие первого порядка для седловых точек, (3) пара дивергенций Брегмана и их свойства, (4) концентрационная лемма, (5) аналоги ключевых утверждений из [1], (6) сборка основной теоремы, (7) обсуждение нижней границы.

2 Исходная задача и результат Carmon–Livni–Yehudayoff

2.1 Постановка задачи минимизации

Пусть $\|\cdot\|$ — норма на $\mathbb{R}^d$, K — её единичный шар, $\mathcal{Z}$ — конечное пространство данных, $\mathcal{D}$ — распределение на $\mathcal{Z}$. Для каждого $z \in \mathcal{Z}$ задана функция $f_z : K \rightarrow \mathbb{R}$,

выпуклая и L -липшицева. Популяционный и эмпирический риски:

$$F(x) = \mathbb{E}_{z \sim \mathcal{D}}[f_z(x)], \quad \hat{F}(x) = \frac{1}{n} \sum_{i=1}^n f_{z_i}(x).$$

ERM — любой алгоритм, возвращающий $\hat{x} \in \operatorname{argmin}_{x \in K} \hat{F}(x)$. Критерий успеха: $F(\hat{x}) \leq F(x^*) + \varepsilon$.

2.2 Главный результат

Теорема 2.1 (Carmon, Livni, Yehudayoff [1], теорема для ℓ_2). Пусть f_z выпуклы, 1-липшицевы по $\|\cdot\|_2$ и $|f_z(x)| \leq 1$ для всех $x \in B$. Если

$$n \geq n_0 = \frac{3d \ln(40/\varepsilon)}{\varepsilon} + \frac{40}{\varepsilon^2},$$

то с вероятностью не менее $3/4$ над $S \sim \mathcal{D}^n$, для всех $x \in B$:

$$\hat{F}(x) \leq \hat{F}(x^*) + \varepsilon \Rightarrow F(x) \leq F(x^*) + 40\varepsilon.$$

2.3 Ключевые идеи доказательства

Доказательство опирается на три элемента:

1. **Стохастическое условие первого порядка.** В минимуме x^* существует субградиент $G \in \partial F(x^*)$ вида $G = \mathbb{E}_z[g_z]$, где $g_z \in \partial f_z(x^*)$, такой что $\langle G, x - x^* \rangle \geq 0$ для всех $x \in K$.
2. **Дивергенция Брегмана.** $D_F(x, x^*) = F(x) - F(x^*) - \langle G, x - x^* \rangle \geq 0$, ограничена сверху константой. Эмпирическая версия $\hat{D}(x, x^*)$ является несмещённой оценкой $D_F(x, x^*)$.
3. **Концентрация.** Если $D_F(x, x^*) \geq 2\varepsilon$, то:

$$\mathbb{P}\left[\hat{D}(x, x^*) \leq \frac{D_F(x, x^*)}{2}\right] \leq \exp\left(-\frac{D_F(x, x^*) \cdot n}{40}\right).$$

Ключевой выигрыш: экспонента $\propto D \cdot n$ (а не $D^2 \cdot n$), что даёт d/ε вместо d/ε^2 . Затем union bound по ε -сети размера $(1/\varepsilon)^d$ завершает доказательство.

Это разделяет ERM ($\tilde{O}(d/\varepsilon + 1/\varepsilon^2)$) и равномерную сходимость ($\Theta(d/\varepsilon^2)$): ERM строго эффективнее.

3 Седловая задача: постановка и определения

3.1 Формальная постановка

Пусть $\|\cdot\|_x$ и $\|\cdot\|_y$ — нормы на $\mathbb{R}^{d_x}$ и $\mathbb{R}^{d_y}$ соответственно, $\mathcal{X}$ и $\mathcal{Y}$ — их единичные шары. Пусть $\mathcal{Z}$ — конечное пространство данных, $\mathcal{D}$ — распределение на $\mathcal{Z}$. Для каждого $z \in \mathcal{Z}$ задана функция $f_z : \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}$, удовлетворяющая:

- $f_z(\cdot, y)$ выпукла и L -липшицева по $\|\cdot\|_x$ для всех y ,
- $f_z(x, \cdot)$ вогнута и L -липшицева по $\|\cdot\|_y$ для всех x ,
- $|f_z(x, y)| \leq c$ для всех $(x, y) \in \mathcal{X} \times \mathcal{Y}$.

Определение 3.1 (Популяционный функционал).

$$F(x, y) = \mathbb{E}_{z \sim \mathcal{D}}[f_z(x, y)].$$

Функция $F(\cdot, y)$ выпукла по x , $F(x, \cdot)$ вогнута по y .

Определение 3.2 (Седловая точка). Точка $(x^*, y^*) \in \mathcal{X} \times \mathcal{Y}$ называется *седловой точкой* F , если

$$F(x^*, y) \leq F(x^*, y^*) \leq F(x, y^*) \quad \forall x \in \mathcal{X}, y \in \mathcal{Y}.$$

Множество всех седловых точек обозначим $\text{SP}(F)$.

Замечание 3.3. Седловая точка существует, поскольку F выпукло-вогнута и непрерывна на компактных выпуклых множествах $\mathcal{X}, \mathcal{Y}$ (теорема Сиона–Какутани).

Определение 3.4 (Эмпирический функционал и Saddle-ERM). По выборке $S = (z_1, \dots, z_n) \sim \mathcal{D}^n$ определяется:

$$\hat{F}(x, y) = \frac{1}{n} \sum_{i=1}^n f_{z_i}(x, y).$$

Saddle-ERM — любой алгоритм, возвращающий $(\hat{x}, \hat{y}) \in \text{SP}(\hat{F})$, то есть седловую точку эмпирического функционала. Такая точка существует по тем же причинам, что и для F .

Определение 3.5 (Duality gap). Для точки $(x, y) \in \mathcal{X} \times \mathcal{Y}$ определим:

$$\text{Gap}_F(x, y) = \max_{y' \in \mathcal{Y}} F(x, y') - \min_{x' \in \mathcal{X}} F(x', y) \geq 0.$$

$\text{Gap}_F(x, y) = 0$ тогда и только тогда, когда $(x, y) \in \text{SP}(F)$. *Saddle-ERM* успешен с параметром $\varepsilon > 0$, если $\text{Gap}_F(\hat{x}, \hat{y}) \leq \varepsilon$.

Замечание 3.6 (Связь с задачей минимизации). Используя $(x^*, y^*) \in \text{SP}(F)$:

$$\text{Gap}_F(x, y) \leq [F(x, y^*) - F(x^*, y^*)] + [F(x^*, y^*) - F(x^*, y)]. \quad (1)$$

Каждое слагаемое неотрицательно и характеризует отклонение от x^* и от y^* соответственно.

4 Вспомогательные результаты

4.1 Субградиентное исчисление

Субградиент выпуклой функции $h : \mathcal{X} \rightarrow \mathbb{R}$ в точке x_0 :

$$\partial_x h(x_0) = \{g \in \mathbb{R}^{d_x} : h(x) \geq h(x_0) + \langle g, x - x_0 \rangle \quad \forall x \in \mathcal{X}\}.$$

Для вогнутой функции $h : \mathcal{Y} \rightarrow \mathbb{R}$ субградиент определяем через $-h$:

$$\partial_y^- h(y_0) = \{g \in \mathbb{R}^{d_y} : h(y) \leq h(y_0) + \langle g, y - y_0 \rangle \quad \forall y \in \mathcal{Y}\}.$$

Если h является L -липшицевой по $\|\cdot\|_x$, то $\|g\|_{x,*} \leq L$ для всех $g \in \partial_x h(x_0)$, где $\|\cdot\|_{x,*}$ — двойственная норма.

4.2 Стохастическое условие первого порядка

Предложение 4.1 (Стохастическое условие первого порядка для седловой точки). Пусть $(x^*, y^*) \in \text{SP}(F)$. Тогда для каждого $z \in \mathcal{Z}$ существуют

$$g_z^x \in \partial_x f_z(x^*, y^*), \quad g_z^y \in \partial_y^- f_z(x^*, y^*)$$

с $\|g_z^x\|_{x,*} \leq L$, $\|g_z^y\|_{y,*} \leq L$, такие что, обозначив $G_x = \mathbb{E}_z[g_z^x]$, $G_y = \mathbb{E}_z[g_z^y]$, выполняется:

$$\langle G_x, x - x^* \rangle \geq 0 \quad \forall x \in \mathcal{X}, \quad (2)$$

$$\langle G_y, y - y^* \rangle \geq 0 \quad \forall y \in \mathcal{Y}. \quad (3)$$

Доказательство. **Условие (2).** Поскольку (x^*, y^*) — седловая точка, x^* минимизирует $F(\cdot, y^*)$ на $\mathcal{X}$. По условию первого порядка для выпуклой задачи (см. [3]) существует $G_x \in \partial_x F(x^*, y^*)$ такой, что $\langle G_x, x - x^* \rangle \geq 0$ для всех $x \in \mathcal{X}$. По теореме о сумме субградиентов [3], применённой к $F(\cdot, y^*) = \mathbb{E}_z[f_z(\cdot, y^*)]$, для каждого z существует $g_z^x \in \partial_x f_z(x^*, y^*)$ такой, что $G_x = \mathbb{E}_z[g_z^x]$. Липшицевость даёт $\|g_z^x\|_{x,*} \leq L$.

Условие (3). Аналогично: y^* максимизирует $F(x^*, \cdot)$ на $\mathcal{Y}$, то есть является минимизатором $-F(x^*, \cdot)$. Применяем условие первого порядка к выпуклой функции $-F(x^*, \cdot)$: существует $G_y \in \partial_y(-F)(x^*, y^*) = \partial_y^- F(x^*, y^*)$ такой, что $\langle G_y, y - y^* \rangle \geq 0$. По теореме о сумме субградиентов, $G_y = \mathbb{E}_z[g_z^y]$, $g_z^y \in \partial_y(-f_z)(x^*, y^*)$. $\square$

Замечание 4.2. Условия (2)–(3) образуют *вариационное неравенство*, характеризующее седловую точку. Это двумерный аналог условия $\langle G, x - x^* \rangle \geq 0$ из [1].

4.3 Пара дивергенций Брегмана

Зафиксируем $(x^*, y^*) \in \text{SP}(F)$ и субградиенты G_x, G_y из Предложения 4.1. Зафиксируем также выборочные версии $\hat{G}_x = \frac{1}{n} \sum_i g_{z_i}^x$, $\hat{G}_y = \frac{1}{n} \sum_i g_{z_i}^y$.

Определение 4.3 (Пара дивергенций Брегмана).

$$\begin{aligned} D^x(x, x^*) &= F(x, y^*) - F(x^*, y^*) - \langle G_x, x - x^* \rangle, \\ D^y(y, y^*) &= F(x^*, y^*) - F(x^*, y) - \langle G_y, y - y^* \rangle. \end{aligned}$$

Поточечные (стохастические) версии:

$$\begin{aligned} D_z^x(x, x^*) &= f_z(x, y^*) - f_z(x^*, y^*) - \langle g_z^x, x - x^* \rangle, \\ D_z^y(y, y^*) &= f_z(x^*, y^*) - f_z(x^*, y) - \langle g_z^y, y - y^* \rangle. \end{aligned}$$

Эмпирические версии:

$$\begin{aligned} \hat{D}^x(x, x^*) &= \hat{F}(x, y^*) - \hat{F}(x^*, y^*) - \langle \hat{G}_x, x - x^* \rangle, \\ \hat{D}^y(y, y^*) &= \hat{F}(x^*, y^*) - \hat{F}(x^*, y) - \langle \hat{G}_y, y - y^* \rangle. \end{aligned}$$

Лемма 4.4 (Неотрицательность). Для всех $(x, y) \in \mathcal{X} \times \mathcal{Y}$:

$$D^x(x, x^*) \geq 0, \quad D^y(y, y^*) \geq 0, \quad D_z^x \geq 0, \quad D_z^y \geq 0, \quad \hat{D}^x \geq 0, \quad \hat{D}^y \geq 0.$$

Доказательство. $D^x \geq 0$: функция $F(\cdot, y^*)$ выпукла, $G_x \in \partial_x F(x^*, y^*)$, поэтому по определению субградиента $F(x, y^*) \geq F(x^*, y^*) + \langle G_x, x - x^* \rangle$.

$D^y \geq 0$: функция $-F(x^*, \cdot)$ выпукла, $G_y \in \partial_y(-F)(x^*, y^*)$, поэтому $-F(x^*, y) \geq -F(x^*, y^*) + \langle G_y, y - y^* \rangle$, откуда $D^y \geq 0$.

Для $D_z^x \geq 0$ и $D_z^y \geq 0$ рассуждение аналогично для f_z вместо F . Неотрицательность $\hat{D}^x, \hat{D}^y$ следует как среднее неотрицательных слагаемых. $\square$

Лемма 4.5 (Ограниченность). Для всех $z \in \mathcal{Z}$ и $(x, y) \in \mathcal{X} \times \mathcal{Y}$:

$$0 \leq D_z^x(x, x^*) \leq 4c, \quad 0 \leq D_z^y(y, y^*) \leq 4c.$$

Следовательно, $0 \leq D^x(x, x^*) \leq 4c$ и $0 \leq D^y(y, y^*) \leq 4c$.

Доказательство. Оценим D_z^x сверху. Так как $|f_z| \leq c$:

$$f_z(x, y^*) - f_z(x^*, y^*) \leq 2c.$$

Из липшицевости $f_z(\cdot, y^*)$ при $x, x^* \in \mathcal{X}$:

$$|\langle g_z^x, x - x^* \rangle| \leq \|g_z^x\|_{x,*} \cdot \|x - x^*\|_x \leq L \cdot 2 = 2L.$$

В случае нормированных шаров ($L = c = 1$) получаем $D_z^x \leq 2 + 2 = 4$, откуда в общем случае $D_z^x \leq 4c$. Аналогично для D_z^y . $\square$

Следствие 4.6 (Несмещённость). $\mathbb{E}_{S \sim \mathcal{D}^n}[\hat{D}^x(x, x^*)] = D^x(x, x^*)$ и $\mathbb{E}_{S \sim \mathcal{D}^n}[\hat{D}^y(y, y^*)] = D^y(y, y^*)$.

Доказательство. $\hat{D}^x(x, x^*) = \frac{1}{n} \sum_i D_{z_i}^x(x, x^*)$, поскольку $\hat{F}(x, y^*) - \hat{F}(x^*, y^*) - \langle \hat{G}_x, x - x^* \rangle = \frac{1}{n} \sum_i [f_{z_i}(x, y^*) - f_{z_i}(x^*, y^*) - \langle g_{z_i}^x, x - x^* \rangle]$. Так как z_i i.i.d. из $\mathcal{D}$, то $\mathbb{E}[\hat{D}^x] = \mathbb{E}_z[D_z^x] = D^x$. $\square$

4.4 Связь дивергенций с duality gap

Лемма 4.7 (Разложение гар через дивергенции). Для любой точки $(x, y) \in \mathcal{X} \times \mathcal{Y}$:

$$\text{Gar}_F(x, y) \leq D^x(x, x^*) + D^y(y, y^*) + \langle G_x, x - x^* \rangle + \langle G_y, y - y^* \rangle.$$

Доказательство. Из (1):

$$\begin{aligned} \text{Gar}_F(x, y) &\leq [F(x, y^*) - F(x^*, y^*)] + [F(x^*, y^*) - F(x^*, y)] \\ &= [D^x(x, x^*) + \langle G_x, x - x^* \rangle] + [D^y(y, y^*) + \langle G_y, y - y^* \rangle]. \end{aligned} \quad \square$$

4.5 Концентрационная лемма

Утверждение 4.8 (Концентрация дивергенций Брегмана). При условиях раздела 3 для любых $(x, y) \in \mathcal{X} \times \mathcal{Y}$:

$$\mathbb{P}\left[\hat{D}^x(x, x^*) \leq \frac{D^x(x, x^*)}{2}\right] \leq \exp\left(-\frac{D^x(x, x^*) \cdot n}{40c}\right), \quad (4)$$

$$\mathbb{P}\left[\hat{D}^y(y, y^*) \leq \frac{D^y(y, y^*)}{2}\right] \leq \exp\left(-\frac{D^y(y, y^*) \cdot n}{40c}\right). \quad (5)$$

Доказательство. Докажем (4); доказательство (5) симметрично.

Запишем $\hat{D}^x(x, x^*) = \frac{1}{n} \sum_{j=1}^n R_j$, где $R_j = D_{z_j}^x(x, x^*)$ — i.i.d. случайные величины. По лемме 4.4 и 4.5: $R_j \in [0, 4c]$ и $\mathbb{E}[R_j] = \lambda := D^x(x, x^*)$.

По неравенству Бхатиа–Дэвиса [4]: $\text{Var}(R_j) \leq (4c - \lambda)\lambda \leq 4c\lambda$.

По неравенству Бернштейна:

$$\begin{aligned} \mathbb{P}\left[\hat{D}^x(x, x^*) \leq \frac{\lambda}{2}\right] &= \mathbb{P}\left[\sum_j (R_j - \lambda) \leq -\frac{\lambda n}{2}\right] \\ &\leq \exp\left(-\frac{(\lambda n/2)^2}{2 \cdot 4c\lambda n + 2 \cdot 4c \cdot (\lambda n/2)/3}\right) \\ &= \exp\left(-\frac{\lambda^2 n^2/4}{8c\lambda n + 4c\lambda n/3}\right) \leq \exp\left(-\frac{\lambda n}{40c}\right). \end{aligned} \quad \square$$

5 Аналоги ключевых утверждений для седловой задачи

В этом разделе мы доказываем аналоги Claims 5, 6 из [1] для седлового случая.

5.1 Контроль линейного члена

Обозначим $\delta_x = \|\hat{G}_x - G_x\|_{x,*}$ и $\delta_y = \|\hat{G}_y - G_y\|_{y,*}$. Определим *хорошее событие*:

$$H = \{\delta_x \leq \varepsilon\} \cap \{\delta_y \leq \varepsilon\}.$$

Утверждение 5.1 (Концентрация эмпирических субградиентов).

$$\mathbb{P}[\delta_x^2 > \varepsilon^2] \leq \frac{4L^2}{\varepsilon^2 n}, \quad \mathbb{P}[\delta_y^2 > \varepsilon^2] \leq \frac{4L^2}{\varepsilon^2 n}.$$

В частности, $\mathbb{P}[\neg H] \leq 8L^2/(\varepsilon^2 n)$.

Доказательство. $\mathbb{E}\|\hat{G}_x - G_x\|_{x,*}^2 = \frac{1}{n^2} \sum_j \mathbb{E}\|g_{z_j}^x - G_x\|_{x,*}^2 \leq \frac{4L^2}{n}$ (так как $\|g_z^x\|_{x,*} \leq L$). По неравенству Маркова: $\mathbb{P}[\delta_x^2 > \varepsilon^2] \leq \frac{4L^2}{\varepsilon^2 n}$. Аналогично для δ_y . $\square$

5.2 Утверждение о малости эмпирических дивергенций (аналог Claim 6)

Утверждение 5.2 (Saddle-ERM имеет малые эмпирические дивергенции). Пусть $(\hat{x}, \hat{y}) \in \text{SP}(\hat{F})$. Тогда на событии H :

$$\hat{D}^x(\hat{x}, x^*) + \hat{D}^y(\hat{y}, y^*) \leq 4\varepsilon.$$

Доказательство. Заметим:

$$\begin{aligned} \hat{D}^x(\hat{x}, x^*) + \hat{D}^y(\hat{y}, y^*) &= \hat{F}(\hat{x}, y^*) - \hat{F}(x^*, y^*) - \langle \hat{G}_x, \hat{x} - x^* \rangle \\ &\quad + \hat{F}(x^*, y^*) - \hat{F}(x^*, \hat{y}) - \langle \hat{G}_y, \hat{y} - y^* \rangle \\ &= \hat{F}(\hat{x}, y^*) - \hat{F}(x^*, \hat{y}) - \langle \hat{G}_x, \hat{x} - x^* \rangle - \langle \hat{G}_y, \hat{y} - y^* \rangle. \end{aligned}$$

Из седловой точки $(\hat{x}, \hat{y}) \in \text{SP}(\hat{F})$: $\hat{F}(\hat{x}, y^*) \leq \hat{F}(\hat{x}, \hat{y}) \leq \hat{F}(x^*, \hat{y})$, значит $\hat{F}(\hat{x}, y^*) - \hat{F}(x^*, \hat{y}) \leq 0$.

Поэтому:

$$\begin{aligned} \hat{D}^x + \hat{D}^y &\leq -\langle \hat{G}_x, \hat{x} - x^* \rangle - \langle \hat{G}_y, \hat{y} - y^* \rangle \\ &= -\langle \hat{G}_x - G_x, \hat{x} - x^* \rangle - \langle G_x, \hat{x} - x^* \rangle - \langle \hat{G}_y - G_y, \hat{y} - y^* \rangle - \langle G_y, \hat{y} - y^* \rangle. \end{aligned}$$

Из условий (2)–(3): $-\langle G_x, \hat{x} - x^* \rangle \leq 0$ и $-\langle G_y, \hat{y} - y^* \rangle \leq 0$. На событии H :

$$|\langle \hat{G}_x - G_x, \hat{x} - x^* \rangle| \leq \|\hat{G}_x - G_x\|_{x,*} \cdot \|\hat{x} - x^*\|_x \leq \varepsilon \cdot 2 = 2\varepsilon,$$

аналогично $|\langle \hat{G}_y - G_y, \hat{y} - y^* \rangle| \leq 2\varepsilon$.

Итого: $\hat{D}^x(\hat{x}, x^*) + \hat{D}^y(\hat{y}, y^*) \leq 2\varepsilon + 0 + 2\varepsilon + 0 = 4\varepsilon$. $\square$

5.3 Утверждение о связи гар с дивергенциями (аналог Claim 5)

Утверждение 5.3 (Большой гар влечёт большие дивергенции). Пусть $(\hat{x}, \hat{y}) \in \text{SP}(\hat{F})$. На событии H :

$$\text{Gar}_F(\hat{x}, \hat{y}) \leq D^x(\hat{x}, x^*) + D^y(\hat{y}, y^*) + 4\varepsilon.$$

В частности, если $D^x(\hat{x}, x^*) + D^y(\hat{y}, y^*) \leq C\varepsilon$, то $\text{Gar}_F(\hat{x}, \hat{y}) \leq (C + 4)\varepsilon$.

Доказательство. Из леммы 4.7:

$$\text{Gar}_F(\hat{x}, \hat{y}) \leq D^x + D^y + \langle G_x, \hat{x} - x^* \rangle + \langle G_y, \hat{y} - y^* \rangle.$$

Оценим линейные члены. Из определения $\hat{D}^x$:

$$\langle \hat{G}_x, \hat{x} - x^* \rangle = \hat{F}(\hat{x}, y^*) - \hat{F}(x^*, y^*) - \hat{D}^x(\hat{x}, x^*).$$

Аналогично:

$$\langle \hat{G}_y, \hat{y} - y^* \rangle = \hat{F}(x^*, y^*) - \hat{F}(x^*, \hat{y}) - \hat{D}^y(\hat{y}, y^*).$$

Суммируя:

$$\langle \hat{G}_x, \hat{x} - x^* \rangle + \langle \hat{G}_y, \hat{y} - y^* \rangle = \hat{F}(\hat{x}, y^*) - \hat{F}(x^*, \hat{y}) - \hat{D}^x - \hat{D}^y \leq 0$$

(используем $\hat{F}(\hat{x}, y^*) \leq \hat{F}(x^*, \hat{y})$ из седловой точки и $\hat{D}^x, \hat{D}^y \geq 0$).

Теперь:

$$\begin{aligned} \langle G_x, \hat{x} - x^* \rangle + \langle G_y, \hat{y} - y^* \rangle &= \langle G_x - \hat{G}_x, \hat{x} - x^* \rangle + \langle \hat{G}_x, \hat{x} - x^* \rangle \\ &\quad + \langle G_y - \hat{G}_y, \hat{y} - y^* \rangle + \langle \hat{G}_y, \hat{y} - y^* \rangle \\ &\leq 2\delta_x + 0 + 2\delta_y + 0 \leq 4\varepsilon \end{aligned}$$

на событии H . Подставляя, получаем утверждение. $\square$

6 Основная теорема

6.1 Формулировка

Теорема 6.1 (Сложность выборки Saddle-ERM, случай ℓ_2). Пусть $\|\cdot\|_x = \|\cdot\|_y = \|\cdot\|_2$, $L = 1$, $c = 1$. Для любого $0 < \varepsilon < 1$ если

$$n \geq n_0 = \frac{3(d_x + d_y) \ln(40/\varepsilon)}{\varepsilon} + \frac{80}{\varepsilon^2},$$

то с вероятностью не менее $3/4$ над $S \sim \mathcal{D}^n$ любой Saddle-ERM $(\hat{x}, \hat{y}) \in \text{SP}(\hat{F})$ удовлетворяет:

$$\text{Gar}_F(\hat{x}, \hat{y}) \leq 50\varepsilon.$$

6.2 Доказательство

Доказательство. Определим плохое событие:

$$E = \{(\hat{x}, \hat{y}) \in \text{SP}(\hat{F}) : \text{Gap}_F(\hat{x}, \hat{y}) > 50\varepsilon\}.$$

Покажем, что $\mathbb{P}[E] \leq 1/4$.

Шаг 1: Хорошее событие H . По утверждению 5.1:

$$\mathbb{P}[\neg H] \leq \frac{8}{\varepsilon^2 n} \leq \frac{1}{8}$$

при $n \geq 64/\varepsilon^2$.

Шаг 2: Работаем на событии H . Предположим, что $E \cap H$ произошло. По утверждению 5.3: если $\text{Gap}_F(\hat{x}, \hat{y}) > 50\varepsilon$, то

$$D^x(\hat{x}, x^*) + D^y(\hat{y}, y^*) > 46\varepsilon.$$

Шаг 3: ε -сеть по $\mathcal{X} \times \mathcal{Y}$. Пусть $\mathcal{N}_x$ — $(\varepsilon/3)$ -сеть по $\mathcal{X}$ и $\mathcal{N}_y$ — $(\varepsilon/3)$ -сеть по $\mathcal{Y}$ (обе по ℓ_2). По лемме о покрывающих числах [1]:

$$|\mathcal{N}_x| \leq \left(\frac{12}{\varepsilon}\right)^{d_x}, \quad |\mathcal{N}_y| \leq \left(\frac{12}{\varepsilon}\right)^{d_y}.$$

Совместная сеть $\mathcal{N} = \mathcal{N}_x \times \mathcal{N}_y$ имеет размер $|\mathcal{N}| \leq (12/\varepsilon)^{d_x+d_y}$.

Поскольку $F(\cdot, y^*)$ и $F(x^*, \cdot)$ являются 1-липшицевыми (по ℓ_2), а $\hat{F}(\cdot, y^*)$ и $\hat{F}(x^*, \cdot)$ — тоже, дивергенции $D^x(\cdot, x^*)$, $D^y(\cdot, y^*)$, $\hat{D}^x(\cdot, x^*)$, $\hat{D}^y(\cdot, y^*)$ являются 2-липшицевыми по ℓ_2 (оценка из ограниченности субградиентов). Значит, для $\|\hat{x} - \tilde{x}\|_2 \leq \varepsilon/3$:

$$|D^x(\hat{x}, x^*) - D^x(\tilde{x}, x^*)| \leq \frac{2\varepsilon}{3},$$

и аналогично для остальных дивергенций.

Для сетевой точки $(\tilde{x}, \tilde{y}) \in \mathcal{N}$ с $\|\hat{x} - \tilde{x}\|_2 \leq \varepsilon/3$, $\|\hat{y} - \tilde{y}\|_2 \leq \varepsilon/3$:

$$D^x(\tilde{x}, x^*) + D^y(\tilde{y}, y^*) \geq 46\varepsilon - \frac{4\varepsilon}{3} > 44\varepsilon,$$

$$\hat{D}^x(\tilde{x}, x^*) + \hat{D}^y(\tilde{y}, y^*) \leq 4\varepsilon + \frac{4\varepsilon}{3} < 6\varepsilon.$$

(Последнее — из утверждения 5.2 и липшицевости $\hat{D}^x, \hat{D}^y$.)

Шаг 4: Концентрационный аргумент. Из $D^x(\tilde{x}, x^*) + D^y(\tilde{y}, y^*) > 44\varepsilon$ следует: хотя бы одно из $D^x(\tilde{x}, x^*) > 22\varepsilon$ или $D^y(\tilde{y}, y^*) > 22\varepsilon$. Предположим $D^x(\tilde{x}, x^*) > 22\varepsilon$ (случай $D^y > 22\varepsilon$ симметричен).

По утверждению 4.8:

$$\mathbb{P}\left[\hat{D}^x(\tilde{x}, x^*) \leq \frac{D^x(\tilde{x}, x^*)}{2}\right] \leq \exp\left(-\frac{22\varepsilon \cdot n}{40}\right) = \exp\left(-\frac{11\varepsilon n}{20}\right).$$

Но мы показали, что на $E \cap H$ выполнено $\hat{D}^x(\tilde{x}, x^*) \leq 6\varepsilon < 11\varepsilon = D^x/2$. Значит, событие $E \cap H$ влечёт для соответствующего $(\tilde{x}, \tilde{y}) \in \mathcal{N}$: $\hat{D}^x(\tilde{x}, x^*) \leq D^x(\tilde{x}, x^*)/2$.

Обозначим: $E_{(\tilde{x}, \tilde{y})}$ — событие $\{\hat{D}^x(\tilde{x}, x^*) \leq D^x(\tilde{x}, x^*)/2\}$ или $\{\hat{D}^y(\tilde{y}, y^*) \leq D^y(\tilde{y}, y^*)/2\}$ (в зависимости от того, какая дивергенция велика). Тогда:

$$E \cap H \subseteq \bigcup_{(\tilde{x}, \tilde{y}) \in \mathcal{N}} E_{(\tilde{x}, \tilde{y})}.$$

Шаг 5: Union bound. По union bound:

$$\mathbb{P}[E \cap H] \leq |\mathcal{N}| \cdot \exp\left(-\frac{11\varepsilon n}{20}\right) \leq \left(\frac{12}{\varepsilon}\right)^{d_x+d_y} \exp\left(-\frac{11\varepsilon n}{20}\right).$$

Для $n \geq \frac{3(d_x+d_y) \ln(40/\varepsilon)}{\varepsilon}$ правая часть $\leq 1/8$.

Итог:

$$\mathbb{P}[E] \leq \mathbb{P}[\neg H] + \mathbb{P}[E \cap H] \leq \frac{1}{8} + \frac{1}{8} = \frac{1}{4}. \quad \square$$

6.3 Обобщение на произвольные нормы

Теорема 6.2 (Общие нормы). Пусть $\|\cdot\|_x, \|\cdot\|_y$ — произвольные нормы. Для любых $0 < \varepsilon, \delta < 1$, если

$$n \geq n_0 = \frac{12cd_x}{\varepsilon} \ln \frac{3L}{\varepsilon} + \frac{12cd_y}{\varepsilon} \ln \frac{3L}{\varepsilon} + \text{Rad}_{\mathcal{X}}^{-1}\left(\frac{\varepsilon}{2L}\right) + \text{Rad}_{\mathcal{Y}}^{-1}\left(\frac{\varepsilon}{2L}\right) + \frac{16c^2}{\varepsilon^2} \ln \frac{8}{\delta},$$

то с вероятностью не менее $1-\delta$ любой Saddle-ERM $(\hat{x}, \hat{y})$ удовлетворяет $\text{Gap}_F(\hat{x}, \hat{y}) \leq C\varepsilon$ для абсолютной константы C .

Набросок доказательства. Вместо $\|\hat{G}_x - G_x\|_{x,*} \leq \varepsilon$ и $\|\hat{G}_y - G_y\|_{y,*} \leq \varepsilon$ (которые контролировались через дисперсию в случае ℓ_2) используется понятие *representativeness* из [1]:

$$\text{Rep}_x(S) = \sup_{x \in \mathcal{X}} (\mathcal{L}_x(x) - \hat{\mathcal{L}}_x(x)), \quad \text{Rep}_y(S) = \sup_{y \in \mathcal{Y}} (\mathcal{L}_y(y) - \hat{\mathcal{L}}_y(y)),$$

где $\mathcal{L}_x, \mathcal{L}_y$ — линейные аппроксимации функционалов, связанные с субградиентами g_z^x, g_z^y соответственно. По следствию 1 из [1] (применённому дважды, к каждой компоненте):

$$\text{Rep}_x(S) \leq 2L \cdot \text{Rad}(\mathcal{X}, n) + c\sqrt{\frac{2 \ln(4/\delta)}{n}}$$

и аналогично для y -компоненты. Это заменяет контроль $\hat{G}_x, \hat{G}_y$ в доказательстве теоремы 6.1. Вместо усечённых дивергенций Брегмана используются усечённые версии T^x, T^y (аналог раздела 6 из [1]). Все остальные шаги переносятся дословно. $\square$

7 Нижняя граница и разделение с равномерной сходимостью

7.1 Нижняя граница

Теорема 7.1 (Нижняя граница для Saddle-ERM, неформально). Для любого алгоритма Saddle-ERM существует распределение $\mathcal{D}$ на классе выпукло-вогнутых функций на $\mathbb{R}^{d_x} \times \mathbb{R}^{d_y}$ такой, что при

$$n \leq c_0 \cdot \frac{d_x + d_y}{\varepsilon}$$

с вероятностью не менее $1/2$: $\text{Gap}_F(\hat{x}, \hat{y}) > \varepsilon$.

Конструкция. Адаптируем конструкцию Фельдмана [2] из задачи минимизации. Там задача $\min_{x \in B^d} F(x)$ сводилась к различению d задач на координатных гиперплоскостях. Для седловой задачи берём функцию $f_z(x, y) = f_z^{(x)}(x) - f_z^{(y)}(y)$, где $f_z^{(x)}$ — конструкция Фельдмана по x , $f_z^{(y)}$ — по y , независимые. Тогда:

- $f_z(x, y)$ выпукла по x и вогнута по y ,
- любой Saddle-ERM должен одновременно хорошо приближать $\operatorname{argmin}_x F(x, y^*)$ и $\operatorname{argmax}_y F(x^*, y)$,
- поскольку задачи по x и по y независимы, нижняя граница на число точек для каждой из них прибавляется, откуда $n = \Omega((d_x + d_y)/\varepsilon)$.

Член $1/\varepsilon^2$ наследуется из нижней границы для агностического обучения, применённой к любой из компонент. $\square$

Замечание 7.2. Строгое доказательство нижней границы требует точного анализа того, что информация о x -компоненте не помогает оценить y -компоненту (и наоборот) при независимой конструкции. Это следует из независимости выборок, участвующих в двух подзадачах, что выполняется при нашей конструкции.

7.2 Разделение с равномерной сходимостью

Теорема 7.3 (Разделение Saddle-ERM и равномерной сходимости). *Существуют классы выпукло-вогнутых функций такие, что:*

1. Любой Saddle-ERM успешен при $n = \tilde{O}((d_x + d_y)/\varepsilon + 1/\varepsilon^2)$.
2. Равномерная сходимость требует $n = \Omega((d_x + d_y)/\varepsilon^2)$.

В частности, Saddle-ERM строго эффективнее равномерной сходимости.

Набросок. Верхняя граница для Saddle-ERM — теорема 6.1. Нижняя граница для равномерной сходимости следует из того, что равномерная сходимость $\sup_{(x,y) \in \mathcal{X} \times \mathcal{Y}} |F(x, y) - \hat{F}(x, y)| \leq \varepsilon$ требует $n = \Omega((d_x + d_y)/\varepsilon^2)$ по размерностным аргументам (аналог теоремы Фельдмана [2]). Действительно, для разделения равномерной сходимости и Saddle-ERM мы можем использовать ту же конструкцию с аддитивной функцией: равномерная сходимость должна контролировать все (x, y) -пары одновременно, что требует в $1/\varepsilon$ раз больше точек по d -размерному члену. $\square$

8 Заключение

В работе мы обобщили результат Carmon, Livni, Yehudayoff [1] на стохастические седловые задачи.

Основные результаты:

1. Определены понятия Saddle-ERM и duality gap как критерия успеха в стохастической выпукло-вогнутой оптимизации.
2. Доказано стохастическое условие первого порядка для седловых точек (Предложение 4.1), обобщающее Proposition 3 из [1].

3. Введена пара дивергенций Брегмана (D^x, D^y) ; доказаны их неотрицательность (лемма 4.4), ограниченность (лемма 4.5) и несмещённость (следствие 4.6).
4. Доказана концентрационная лемма (утверждение 4.8) — аналог Claim 7 из [1].
5. Доказаны аналоги Claims 5, 6: утверждения 5.2–5.3, устанавливающие связь между Saddle-ERM и дивергенциями.
6. Доказана основная теорема 6.1: сложность выборки Saddle-ERM равна $\tilde{O}((d_x + d_y)/\varepsilon + 1/\varepsilon^2)$.
7. Обсуждены нижняя граница и разделение с равномерной сходимостью.

Главный структурный вывод. Ключевой шаг оригинальной статьи — доказательство того, что $\hat{D}$ мало для ERM, — переносится на седловой случай через тождество:

$$\hat{D}^x(\hat{x}, x^*) + \hat{D}^y(\hat{y}, y^*) = \hat{F}(\hat{x}, y^*) - \hat{F}(x^*, \hat{y}) - \langle \hat{G}_x, \hat{x} - x^* \rangle - \langle \hat{G}_y, \hat{y} - y^* \rangle,$$

где первое слагаемое ≤ 0 по седловому условию, а линейные члены малы по концентрации. Это позволяет применить стандартный аргумент ε -сети по совместному пространству $\mathcal{X} \times \mathcal{Y}$.

Открытые вопросы. Строгое доказательство нижней границы $\Omega((d_x + d_y)/\varepsilon)$, точный аналог теоремы 6.2 с проверкой совместной Радемахеровской сложности, а также вопрос о разделении с равномерной сходимостью в содержательном классе функций остаются направлениями дальнейших исследований.

Список литературы

- [1] D. Carmon, R. Livni, A. Yehudayoff. *The Sample Complexity of ERM in Stochastic Convex Optimization*. arXiv:2311.05398, 2023.
- [2] V. Feldman. *Generalization of ERM in Stochastic Convex Optimization: The Dimension Strikes Back*. Advances in Neural Information Processing Systems 29, 2016.
- [3] R. T. Rockafellar. *Convex Analysis*. Princeton University Press, 1997.
- [4] R. Bhatia, C. Davis. *A better bound on the variance*. American Mathematical Monthly, 107(4):353–357, 2000.
- [5] S. Shalev-Shwartz, S. Ben-David. *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press, 2014.
- [6] S. Bubeck. *Convex Optimization: Algorithms and Complexity*. Foundations and Trends in Machine Learning, 8(3–4):231–357, 2015.
- [7] A. Nemirovski, A. Juditsky, G. Lan, A. Shapiro. *Robust Stochastic Approximation Approach to Stochastic Programming*. SIAM Journal on Optimization, 19(4):1574–1609, 2009.