

Обобщение результатов Carmon, Livni,
Yehudayoff (2023)
на седловые задачи

Рабочие заметки

Содержание

1. Исходная статья: постановка и главный результат

1.1. Контекст

Статья “*The Sample Complexity of ERM in Stochastic Convex Optimization*” (Carmon, Livni, Yehudayoff, 2023) решает открытую проблему, поставленную Фельдманом в 2016 году: **сколько точек данных необходимо и достаточно, чтобы любой ERM показывал хорошее качество на истинном распределении?**

1.2. Формальная постановка задачи минимизации

Пусть $\|\cdot\|$ — норма на $\mathbb{R}^d$, K — её единичный шар, Z — пространство данных, $\mathcal{D}$ — неизвестное распределение на Z .

Для каждого $z \in Z$ задана функция $f_z : K \rightarrow \mathbb{R}$, выпуклая и L -липшицева.

Определение 1 (Популяционный риск).

$$F(x) = \mathbb{E}_{z \sim \mathcal{D}}[f_z(x)]$$

Истинный оптимум: $x^* \in \operatorname{argmin}_{x \in K} F(x)$.

Определение 2 (Эмпирический риск и ERM). По выборке $S = (z_1, \dots, z_n) \sim \mathcal{D}^n$ определяется эмпирический риск:

$$\hat{F}(x) = \frac{1}{n} \sum_{i=1}^n f_{z_i}(x)$$

ERM (Empirical Risk Minimizer) — любой алгоритм, возвращающий

$$\hat{x} \in \operatorname{argmin}_{x \in K} \hat{F}(x).$$

Критерий успеха ERM:

$$F(\hat{x}) \leq F(x^*) + \varepsilon.$$

1.3. Главный результат статьи

Теорема 1 (Carmon, Livni, Yehudayoff, 2023 — Теорема 1, ℓ_2 случай). Пусть f_z выпуклы, 1-липшицевы по $\|\cdot\|_2$ и $|f_z(x)| \leq 1$ для всех $x \in B$. Если

$$n \geq n_0 = \frac{3d \ln(40/\varepsilon)}{\varepsilon} + \frac{40}{\varepsilon^2},$$

то с вероятностью не менее $3/4$ над $S \sim \mathcal{D}^n$, для всех $x \in B$:

$$\hat{F}(x) \leq \hat{F}(x^*) + \varepsilon \implies F(x) \leq F(x^*) + 40\varepsilon.$$

Теорема 2 (Carmon, Livni, Yehudayoff, 2023 — Теорема 2, общая норма). Для произвольной нормы $\|\cdot\|$ с единичным шаром K , при $n \geq n_0$, где

$$n_0 = \frac{12cd}{\varepsilon} \ln \frac{3L}{\varepsilon} + \operatorname{Rad}_K^{-1}\left(\frac{\varepsilon}{2L}\right) + \frac{8c^2}{\varepsilon^2} \ln \frac{4}{\delta},$$

с вероятностью не менее $1 - \delta$ любой ERM даёт ε -точное решение.

Здесь $\operatorname{Rad}_K^{-1}(\varepsilon)$ — обратная функция Радемахера, характеризующая сложность обучения линейных функций над K .

1.4. Что это означает

- **Закрывает разрыв.** До статьи: нижняя граница $\Omega(d/\varepsilon + 1/\varepsilon^2)$ (Feldman 2016), верхняя $O(d/\varepsilon^2)$. Статья доказывает, что $\tilde{O}(d/\varepsilon + 1/\varepsilon^2)$ *достаточно*.
- **Разделение ERM и равномерной сходимости.** Равномерная сходимость требует $\Theta(d/\varepsilon^2)$ точек. Все ERM работают лучше — им хватает $\tilde{O}(d/\varepsilon + 1/\varepsilon^2)$. В SCO обучение строго проще равномерной сходимости.
- **Два режима в одной модели.** Член $1/\varepsilon^2$ характерен для агностического (шумного) обучения, d/ε — для реализуемого случая. ERM в SCO неожиданно совмещает оба.

1.5. Ключевые идеи доказательства

1. **Стохастическое условие первого порядка (Proposition 3).** В минимуме x^* существует субградиент $G \in \partial F(x^*)$ такой, что $\langle G, x - x^* \rangle \geq 0$ для всех $x \in K$. При этом $G = \mathbb{E}_z[g_z]$, где $g_z \in \partial f_z(x^*)$.
2. **Дивергенция Брегмана.**

$$D_F(x, x^*) = F(x) - F(x^*) - \langle G, x - x^* \rangle \geq 0,$$

всегда неотрицательна и ограничена сверху константой. Эмпирическая версия: $\hat{D}(x, x^*) = \hat{F}(x) - \hat{F}(x^*) - \langle \hat{G}, x - x^* \rangle$.

3. **Концентрация (Claim 7).** Если $D_F(x, x^*) \geq 2\varepsilon$, то:

$$\Pr \left[\hat{D}(x, x^*) \leq \frac{D_F(x, x^*)}{2} \right] \leq \exp \left(-\frac{D_F(x, x^*) \cdot n}{40} \right).$$

Ключевой выигрыш: это экспонента с $D \cdot n$ (а не $D^2 \cdot n$), что даёт d/ε вместо d/ε^2 в итоговой оценке.

4. **Union bound по ε -сети.** Сеть по K размером $(C/\varepsilon)^d$, затем объединение событий концентрации.

2. Обобщение на седловую задачу

2.1. Постановка седловой задачи

Рассматриваем задачу:

$$\min_{x \in \mathcal{X}} \max_{y \in \mathcal{Y}} F(x, y), \quad F(x, y) = \mathbb{E}_{z \sim \mathcal{D}}[f(x, y, z)],$$

где:

- $\mathcal{X} \subset \mathbb{R}^{d_x}$, $\mathcal{Y} \subset \mathbb{R}^{d_y}$ — единичные шары соответствующих норм,
- $f(\cdot, y, z)$ выпукла по x для всех y, z ,

- $f(x, \cdot, z)$ вогнута по y для всех x, z ,
- f является L -липшицевой по (x, y) , ограниченной: $|f(x, y, z)| \leq c$.

Определение 3 (Седловая точка популяционного функционала). Точка $(x^*, y^*) \in \mathcal{X} \times \mathcal{Y}$ является седловой точкой, если:

$$F(x^*, y) \leq F(x^*, y^*) \leq F(x, y^*) \quad \forall x \in \mathcal{X}, y \in \mathcal{Y}.$$

Определение 4 (ERM для седловой задачи). По выборке $S = (z_1, \dots, z_n)$ определяется эмпирический функционал:

$$\hat{F}(x, y) = \frac{1}{n} \sum_{i=1}^n f(x, y, z_i).$$

Saddle-ERM — любой алгоритм, возвращающий седловую точку $(\hat{x}, \hat{y})$ функционала $\hat{F}$.

Определение 5 (Duality Gap — критерий качества). Качество решения $(\hat{x}, \hat{y})$ измеряется через *duality gap*:

$$\text{Gap}(\hat{x}, \hat{y}) = \max_{y \in \mathcal{Y}} F(\hat{x}, y) - \min_{x \in \mathcal{X}} F(x, \hat{y}) \geq 0.$$

ERM считается успешным, если $\text{Gap}(\hat{x}, \hat{y}) \leq \varepsilon$.

2.2. Адаптация ключевых элементов доказательства

2.2.1. Условие первого порядка

В задаче минимизации: в оптимуме x^* существует $G \in \partial F(x^*)$ такой, что $\langle G, x - x^* \rangle \geq 0$ для всех $x \in \mathcal{X}$.

В седловой задаче: в седловой точке (x^*, y^*) существуют $G_x \in \partial_x F(x^*, y^*)$ и $G_y \in \partial_y (-F)(x^*, y^*)$ такие, что:

$$\langle G_x, x - x^* \rangle \geq 0 \quad \forall x \in \mathcal{X},$$

$$\langle G_y, y - y^* \rangle \geq 0 \quad \forall y \in \mathcal{Y}.$$

Стохастические версии: $G_x = \mathbb{E}_z[g_z^x]$, $G_y = \mathbb{E}_z[g_z^y]$, где $g_z^x \in \partial_x f_z(x^*, y^*)$, $g_z^y \in \partial_y (-f_z)(x^*, y^*)$.

2.2.2. Дивергенция Брегмана для седловой задачи

Вводим пару дивергенций. Для фиксированной седловой точки (x^*, y^*) :

$$D^x(x, x^*) = F(x, y^*) - F(x^*, y^*) - \langle G_x, x - x^* \rangle \geq 0,$$

$$D^y(y, y^*) = F(x^*, y) - F(x^*, y^*) - \langle G_y, y - y^* \rangle \geq 0.$$

Обе дивергенции неотрицательны в силу выпукло-вогнутой структуры F . Интуиция: D^x измеряет, насколько x хуже x^* при фиксированном y^* , а D^y — насколько y хуже y^* при фиксированном x^* .

Связь с duality gap:

$$\begin{aligned}\text{Gap}(x, y) &= \max_{y'} F(x, y') - \min_{x'} F(x', y) \\ &\leq [F(x, y^*) - F(x^*, y^*)] + [F(x^*, y^*) - F(x^*, y)] \\ &= D^x(x, x^*) + \langle G_x, x - x^* \rangle + D^y(y, y^*) + \langle G_y, y - y^* \rangle.\end{aligned}$$

Если x и y близки к x^* и y^* соответственно, то линейные остатки малы.

2.2.3. Концентрация

Аналогично Claim 7 из оригинала, ожидается:

$$\Pr\left[\hat{D}^x(x, x^*) \leq \frac{D^x(x, x^*)}{2}\right] \leq \exp\left(-\frac{D^x(x, x^*) \cdot n}{C}\right),$$

и симметрично для D^y . Это должно следовать из тех же инструментов (неравенство Бхатиа-Дэвиса + Бернштейн), при условии ограниченности дивергенций.

2.2.4. Union bound и ε -сеть

Берётся совместная ε -сеть по $(x, y) \in \mathcal{X} \times \mathcal{Y}$:

$$|N| \leq \left(\frac{C}{\varepsilon}\right)^{d_x + d_y}.$$

В итоговой оценке $d = d_x + d_y$.

2.3. Ожидаемый результат

Если обобщение проходит по описанной схеме, ожидаемая сложность выборки для Saddle-ERM:

$$n = \tilde{O}\left(\frac{d_x + d_y}{\varepsilon} + \frac{1}{\varepsilon^2}\right).$$

3. Открытые вопросы обобщения

Открытый вопрос 1 (Корректность определения Saddle-ERM). Что именно считать ERM в седловой задаче? В задаче минимизации ERM однозначен: это $\arg\min \hat{F}$. В седловой задаче эмпирическая седловая точка может:

- не существовать (если $\hat{F}$ не имеет седловой точки),
- не быть единственной,
- быть вычислительно труднодостижимой.

Нужно ли предполагать существование и единственность седловой точки $\hat{F}$, или можно работать с приближёнными седловыми точками?

Открытый вопрос 2 (Корректность критерия качества). *Duality gap* — естественный критерий, но он несимметричен. Подходит ли он как аналог $F(\hat{x}) \leq F(x^*) + \varepsilon$? Как именно связать *gap* с парой дивергенций Брегмана? Не теряется ли информация при таком разделении на D^x и D^y ?

Открытый вопрос 3 (Стохастическое условие первого порядка). В оригинале ключевую роль играет Proposition 3: существование субградиента G такого, что $\langle G, x - x^* \rangle \geq 0$. Какова аналогичная структура для седловых точек? В частности, нужна ли версия *subgradient sum theorem* для пары (G_x, G_y) , и как она формулируется в стохастическом случае?

Открытый вопрос 4 (Ограниченность эмпирической дивергенции Брегмана). В оригинале $D_{f_z}(x, x^*) \in [0, 4]$ — ключевое свойство для применения Бернштейна. В седловой задаче нужно, чтобы $D_{f_z}^x(x, x^*) \in [0, C_1]$ и $D_{f_z}^y(y, y^*) \in [0, C_2]$ были ограничены. При каких условиях это выполняется? Достаточно ли ограниченности f_z и липшицевости?

Открытый вопрос 5 (Совместная концентрация двух дивергенций). В оригинале концентрация применяется к одной дивергенции. В седловой задаче D^x и D^y зависимы, так как вычисляются в одной точке (x^*, y^*) и по одной выборке. Как аккуратно провести совместную концентрацию? Достаточно ли простого *union bound*, или нужна более тонкая оценка?

Открытый вопрос 6 (Граница по общей норме). В оригинале Теорема 2 даёт для общих норм член $\text{Rad}_K^{-1}(\varepsilon/L)$, связанный со сложностью линейных функций. Каков аналог для седловой задачи? Появятся ли два отдельных члена Rad_x^{-1} и Rad_y^{-1} , или нужна совместная Радемахеровская сложность пары (x, y) ?

Открытый вопрос 7 (Нижняя граница). Статья закрывает разрыв для задачи минимизации: нижняя граница Фельдмана совпадает с новой верхней. Какова нижняя граница для *Saddle-ERM*? Есть ли аналог конструкции Фельдмана для седловых задач, доказывающий $\Omega((d_x + d_y)/\varepsilon + 1/\varepsilon^2)$?

Открытый вопрос 8 (Разделение с равномерной сходимостью). Один из главных выводов оригинала: *ERM* лучше равномерной сходимости. Сохраняется ли это разделение в седловой задаче? Какова сложность равномерной сходимости в *min-tasks SCO*, и остаётся ли она хуже, чем $\tilde{O}((d_x + d_y)/\varepsilon + 1/\varepsilon^2)$?

4. Выполнение первых трёх пунктов дорожной карты

4.1. Пункт 1: Определения *Saddle-ERM* и *duality gap*

Зафиксируем обозначения, которые будут использоваться далее.

Пусть $\|\cdot\|_x$ и $\|\cdot\|_y$ — нормы на $\mathbb{R}^{d_x}$ и $\mathbb{R}^{d_y}$ соответственно, $\mathcal{X}$ и $\mathcal{Y}$ — их единичные шары. Пусть Z — конечное пространство данных, $\mathcal{D}$ — распределение на Z .

Для каждого $z \in Z$ задана функция $f_z : \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}$, удовлетворяющая:

- $f_z(\cdot, y)$ выпукла и L -липшицева по $\|\cdot\|_x$ для всех y ,
- $f_z(x, \cdot)$ вогнута и L -липшицева по $\|\cdot\|_y$ для всех x ,
- $|f_z(x, y)| \leq c$ для всех $(x, y) \in \mathcal{X} \times \mathcal{Y}$.

Определение 6 (Популяционный функционал).

$$F(x, y) = \mathbb{E}_{z \sim \mathcal{D}}[f_z(x, y)].$$

Функция $F(\cdot, y)$ выпукла по x , $F(x, \cdot)$ вогнута по y .

Определение 7 (Седловая точка). Точка $(x^*, y^*) \in \mathcal{X} \times \mathcal{Y}$ называется седловой точкой F , если

$$F(x^*, y) \leq F(x^*, y^*) \leq F(x, y^*) \quad \forall x \in \mathcal{X}, \forall y \in \mathcal{Y}.$$

Обозначим множество всех седловых точек через $\text{SP}(F)$.

Замечание 1. Седловая точка существует, так как F выпукло-вогнута и непрерывна на компактных выпуклых множествах $\mathcal{X}$, $\mathcal{Y}$ (теорема Сиона-Какутани).

Определение 8 (Эмпирический функционал и Saddle-ERM). По выборке $S = (z_1, \dots, z_n) \sim \mathcal{D}^n$ определяется:

$$\hat{F}(x, y) = \frac{1}{n} \sum_{i=1}^n f_{z_i}(x, y).$$

Saddle-ERM — любой алгоритм, возвращающий

$$(\hat{x}, \hat{y}) \in \text{SP}(\hat{F}),$$

то есть седловую точку эмпирического функционала $\hat{F}$. Седловая точка $\hat{F}$ существует по тем же причинам, что и для F .

Определение 9 (Duality gap и критерий успеха). Для точки $(x, y) \in \mathcal{X} \times \mathcal{Y}$ определим duality gap:

$$\text{Gap}_F(x, y) = \max_{y' \in \mathcal{Y}} F(x, y') - \min_{x' \in \mathcal{X}} F(x', y).$$

Заметим, что $\text{Gap}_F(x, y) \geq 0$ всегда, и $\text{Gap}_F(x^*, y^*) = 0$ тогда и только тогда, когда (x^*, y^*) является седловой точкой.

Критерий успеха Saddle-ERM: алгоритм успешен с параметром $\varepsilon > 0$, если

$$\text{Gap}_F(\hat{x}, \hat{y}) \leq \varepsilon.$$

Замечание 2 (Связь с задачей минимизации). В задаче минимизации критерий $F(\hat{x}) \leq F(x^*) + \varepsilon$ эквивалентен контролю одного отклонения. В седловой задаче duality gap одновременно контролирует качество $\hat{x}$ как «игрока-минимизатора» и $\hat{y}$ как «игрока-максимизатора»:

$$\text{Gap}_F(\hat{x}, \hat{y}) \leq \underbrace{[F(\hat{x}, y^*) - F(x^*, y^*)]}_{\text{отклонение по } x} + \underbrace{[F(x^*, y^*) - F(x^*, \hat{y})]}_{\text{отклонение по } y}.$$

4.2. Пункт 2: Стохастическое условие первого порядка

Сначала напомним субградиентное исчисление, которое потребуется.

Определение 10 (Субградиент по x и по y). Для функции $h : \mathcal{X} \rightarrow \mathbb{R}$ выпуклой:

$$\partial_x h(x_0) = \{g \in \mathbb{R}^{d_x} : h(x) \geq h(x_0) + \langle g, x - x_0 \rangle \forall x \in \mathcal{X}\}.$$

Для функции $h : \mathcal{Y} \rightarrow \mathbb{R}$ вогнутой субградиент определяется как субградиент $-h$:

$$\partial_y^- h(y_0) = \{g \in \mathbb{R}^{d_y} : h(y) \leq h(y_0) + \langle g, y - y_0 \rangle \forall y \in \mathcal{Y}\}.$$

Предложение 1 (Стохастическое условие первого порядка для седловой точки). Пусть $(x^*, y^*) \in \text{SP}(F)$. Тогда для каждого $z \in Z$ существуют

$$g_z^x \in \partial_x f_z(x^*, y^*), \quad g_z^y \in \partial_y^- f_z(x^*, y^*)$$

с $\|g_z^x\|_{x,*} \leq L$ и $\|g_z^y\|_{y,*} \leq L$, такие что, обозначив $G_x = \mathbb{E}_{z \sim \mathcal{D}}[g_z^x]$ и $G_y = \mathbb{E}_{z \sim \mathcal{D}}[g_z^y]$, выполняется:

$$\langle G_x, x - x^* \rangle \geq 0 \quad \forall x \in \mathcal{X}, \quad (1)$$

$$\langle G_y, y - y^* \rangle \geq 0 \quad \forall y \in \mathcal{Y}. \quad (2)$$

Доказательство. Доказательство проводится отдельно для каждой координаты.

Условие по x . Так как (x^*, y^*) — седловая точка, то x^* является минимизатором $F(\cdot, y^*)$ на $\mathcal{X}$. По условию первого порядка для выпуклой задачи (аналог Proposition 3 из оригинальной статьи) существует $G_x \in \partial_x F(x^*, y^*)$ такой, что

$$\langle G_x, x - x^* \rangle \geq 0 \quad \forall x \in \mathcal{X}.$$

Применяя теорему о сумме субградиентов к $F(\cdot, y^*) = \mathbb{E}_z[f_z(\cdot, y^*)]$, получаем, что для каждого z существует $g_z^x \in \partial_x f_z(x^*, y^*)$ такой, что $G_x = \mathbb{E}_z[g_z^x]$. Так как $f_z(\cdot, y^*)$ является L -липшицевой по $\|\cdot\|_x$, то $\|g_z^x\|_{x,*} \leq L$.

Условие по y . Аналогично: (x^*, y^*) — седловая точка, значит y^* является максимизатором $F(x^*, \cdot)$ на $\mathcal{Y}$, то есть y^* — минимизатором $-F(x^*, \cdot)$. Применяем условие первого порядка к выпуклой функции $-F(x^*, \cdot)$: существует $G_y \in \partial_y(-F)(x^*, y^*) = \partial_y^- F(x^*, y^*)$ такой, что

$$\langle G_y, y - y^* \rangle \geq 0 \quad \forall y \in \mathcal{Y}.$$

По теореме о сумме субградиентов, $G_y = \mathbb{E}_z[g_z^y]$, где $g_z^y \in \partial_y(-f_z)(x^*, y^*)$. Липшицевость даёт $\|g_z^y\|_{y,*} \leq L$. $\square$

Замечание 3. Условия (??) и (??) вместе образуют вариационное неравенство, характеризующее седловую точку. Это аналог $\langle G, x - x^* \rangle \geq 0$ из оригинальной статьи, но двумерный.

4.3. Пункт 3: Дивергенции Брегмана, неотрицательность и ограниченность

Определение 11 (Пара дивергенций Брегмана). Зафиксируем седловую точку (x^*, y^*) и субградиенты G_x, G_y из Предложения ???. Определим:

$$\begin{aligned} D^x(x, x^*) &= F(x, y^*) - F(x^*, y^*) - \langle G_x, x - x^* \rangle, \\ D^y(y, y^*) &= F(x^*, y) - F(x^*, y^*) - \langle G_y, y - y^* \rangle. \end{aligned}$$

Поточечные (стохастические) версии:

$$\begin{aligned} D_z^x(x, x^*) &= f_z(x, y^*) - f_z(x^*, y^*) - \langle g_z^x, x - x^* \rangle, \\ D_z^y(y, y^*) &= f_z(x^*, y) - f_z(x^*, y^*) - \langle g_z^y, y - y^* \rangle. \end{aligned}$$

Эмпирические версии по выборке S :

$$\begin{aligned} \hat{D}^x(x, x^*) &= \hat{F}(x, y^*) - \hat{F}(x^*, y^*) - \langle \hat{G}_x, x - x^* \rangle, \\ \hat{D}^y(y, y^*) &= \hat{F}(x^*, y) - \hat{F}(x^*, y^*) - \langle \hat{G}_y, y - y^* \rangle, \end{aligned}$$

где $\hat{G}_x = \frac{1}{n} \sum_i g_{z_i}^x$ и $\hat{G}_y = \frac{1}{n} \sum_i g_{z_i}^y$.

Лемма 1 (Неотрицательность). Для всех $(x, y) \in \mathcal{X} \times \mathcal{Y}$:

$$D^x(x, x^*) \geq 0, \quad D^y(y, y^*) \geq 0.$$

Аналогично, $D_z^x \geq 0, D_z^y \geq 0, \hat{D}^x \geq 0, \hat{D}^y \geq 0$.

Доказательство. Неотрицательность D^x . Функция $F(\cdot, y^*)$ выпукла, а $G_x \in \partial_x F(x^*, y^*)$. По определению субградиента:

$$F(x, y^*) \geq F(x^*, y^*) + \langle G_x, x - x^* \rangle,$$

откуда $D^x(x, x^*) \geq 0$.

Неотрицательность D^y . Функция $-F(x^*, \cdot)$ выпукла, а $G_y \in \partial_y (-F)(x^*, y^*)$. По определению субградиента:

$$-F(x^*, y) \geq -F(x^*, y^*) + \langle G_y, y - y^* \rangle,$$

откуда $F(x^*, y^*) - F(x^*, y) \geq \langle G_y, y - y^* \rangle$, то есть $D^y(y, y^*) \geq 0$.

Аналогичные рассуждения дают $D_z^x \geq 0$ и $D_z^y \geq 0$ (применяем к f_z вместо F), а также $\hat{D}^x \geq 0, \hat{D}^y \geq 0$ (как среднее неотрицательных слагаемых). $\square$

Лемма 2 (Ограниченность). Для всех $z \in Z$ и $(x, y) \in \mathcal{X} \times \mathcal{Y}$:

$$0 \leq D_z^x(x, x^*) \leq 4c, \quad 0 \leq D_z^y(y, y^*) \leq 4c.$$

Следовательно, $0 \leq D^x(x, x^*) \leq 4c$ и $0 \leq D^y(y, y^*) \leq 4c$.

Доказательство. Верхняя оценка для D_z^x . По условию $|f_z(x, y)| \leq c$ для всех (x, y) , поэтому:

$$f_z(x, y^*) - f_z(x^*, y^*) \leq 2c.$$

Оценим линейный член снизу. Из условия первого порядка (??):

$$\langle G_x, x - x^* \rangle \geq 0.$$

Однако нам нужна нижняя оценка для $\langle g_z^x, x - x^* \rangle$ по отдельному z , а не в среднем. Так как $g_z^x \in \partial_x f_z(x^*, y^*)$ и $f_z(\cdot, y^*)$ является L -липшицевой, а $x, x^* \in \mathcal{X}$ (единичный шар), то:

$$|\langle g_z^x, x - x^* \rangle| \leq \|g_z^x\|_{x^*} \cdot \|x - x^*\|_x \leq L \cdot 2 = 2L.$$

Из ограниченности f_z и $x, x^* \in \mathcal{X}$ также следует, что $f_z(x, y^*) - f_z(x^*, y^*) \geq -2c$, поэтому:

$$D_z^x(x, x^*) = \underbrace{f_z(x, y^*) - f_z(x^*, y^*)}_{\in [-2c, 2c]} - \underbrace{\langle g_z^x, x - x^* \rangle}_{\geq -2c} \leq 2c + 2c = 4c.$$

Верхняя оценка для D_z^y . Аналогично: $f_z(x^*, y) - f_z(x^*, y^*) \leq 2c$, и $\langle g_z^y, y - y^* \rangle \geq -2c$, откуда $D_z^y \leq 4c$.

Для популяционных дивергенций граница $4c$ следует из линейности ожидания. $\square$

Следствие 1 (Несмещённость эмпирических дивергенций).

$$\begin{aligned} \mathbb{E}_{S \sim \mathcal{D}^n} [\hat{D}^x(x, x^*)] &= D^x(x, x^*), \\ \mathbb{E}_{S \sim \mathcal{D}^n} [\hat{D}^y(y, y^*)] &= D^y(y, y^*). \end{aligned}$$

Доказательство. Запишем:

$$\hat{D}^x(x, x^*) = \frac{1}{n} \sum_{i=1}^n D_{z_i}^x(x, x^*),$$

так как $\hat{F}(x, y^*) - \hat{F}(x^*, y^*) - \langle \hat{G}_x, x - x^* \rangle = \frac{1}{n} \sum_i [f_{z_i}(x, y^*) - f_{z_i}(x^*, y^*) - \langle g_{z_i}^x, x - x^* \rangle]$. Так как z_i i.i.d. из $\mathcal{D}$, то $\mathbb{E}[\hat{D}^x] = \mathbb{E}[D_z^x] = D^x$. Аналогично для $\hat{D}^y$. $\square$

Замечание 4 (Итог пункта 3 и связь с duality gap). Дивергенции D^x и D^y удовлетворяют всем свойствам, необходимым для применения неравенства Бернштейна на следующем шаге:

1. неотрицательны (Лемма ??),
2. ограничены сверху $4c$ (Лемма ??),
3. несмещённо оцениваются эмпирическими версиями (Следствие ??).

Кроме того, из определений и условий первого порядка (??)-(??):

$$\text{Gap}_F(x, y) \leq D^x(x, x^*) + D^y(y, y^*) + \langle G_x, x - x^* \rangle + \langle G_y, y - y^* \rangle.$$

Если $(\hat{x}, \hat{y})$ — Saddle-ERM (седловая точка $\hat{F}$), то $\langle \hat{G}_x, \hat{x} - x^* \rangle \leq 0$ и $\langle \hat{G}_y, \hat{y} - y^* \rangle \leq 0$ не выполняются автоматически, поэтому контроль линейных остатков $\langle G_x, \hat{x} - x^* \rangle$ и $\langle G_y, \hat{y} - y^* \rangle$ потребует отдельного аргумента (аналог контроля $\|\hat{G} - G\|_2$ в оригинале) — это задача пункта 4.

5. Дорожная карта

1. Формально определить Saddle-ERM и duality gap как критерий успеха.
2. Доказать стохастическое условие первого порядка для седловых точек (аналог Proposition 3).
3. Определить пару дивергенций Брегмана, проверить неотрицательность и ограниченность.
4. Доказать концентрацию для каждой дивергенции (аналог Claim 7).
5. Провести union bound по совместной ε -сети $\mathcal{X} \times \mathcal{Y}$.
6. Собрать итоговую оценку сложности выборки.
7. Проверить нижнюю границу и разделение с равномерной сходимостью.